

High-Resolution Image Synthesis With Latent Diffusion Models

INTRODUCTION

- Image Synthesis 연구
 - Image Synthesis 는 최근 가장 많은 발전을 이룬 computer vision 분야 중 하나이며, 가장 큰 computational 수요를 가진 분야
- 기존 연구의 한계점점
 - (GANs)
 - 복잡한 multi-modal distributions 으로 scale 하기 힘든 adversarial learning 으로 인해 제한된 variability 를 가진 data 에 국한
 - DMs
 - pixel space 에서 작동하기 때문에 powerful DMs 의 optimization 은 많은 GPU 가 필요하고 sequential evaluations 로 인해 긴 inference 시간이 필요

INTRODUCTION

Departure to Latent Space

- 대략적인 학습 단계(two stages)
 - a. **perceptual compression** stage
 - high-frequency details 을 제거하지만 아직 semantic variation 은 학습하지 않음.
 - b. **semantic compression** stage
 - 실제 generative model 이 데이터의 semantic and conceptual composition 학습함.
- perceptual and semantic compression
 - digital image 의 대부분의 비트 : imperceptible details
 - DM은 responsible loss term 을 최소화하여 이러한 의미 없는 정보(imperceptible details) 제거 가능 그러나, (during training) gradients 및 neural network backbone (training and inference) 은 여전히 모든 pixel 에서 평가되어 과도한 computations 이 요구됨.

INTRODUCTION

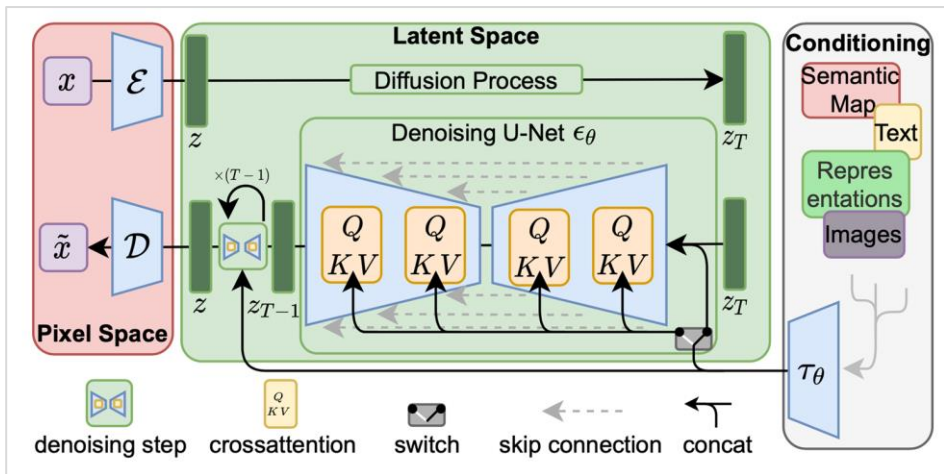
Departure to Latent Space

- 논문의 목표
 - perceptually equivalent + computationally suitable space 찾아서 high-resolution image synthesis 을 위한 diffusion models 훈련
- Latent Diffusion Models(LDMs)
 - 💡 Diffusion Model을 pixel space 가 아닌 pretrained autoencoders 의 latent space 에 적용 + cross-attention layers 도입
→ latent diffusion models (LDMs) 제안
 - data space 와 perceptually equivalent 하면서도 lower-dimensional representational space 제공하는 autoencoder 학습
→ 이전 연구들과 다르게 spatial compression 에 의존할 필요가 없다.
? : spatial dimensionality(공간적 차원; pixel space) 보다 더 좋은 scaling properties 을 가지고 있는 latent space 에서 DM 을 학습하기 때문에
 - lower dimensionality 인 compressed latent space 작동함으로써 2가지 단점을 해결함.
→ 컴퓨팅 리소스 ⬇️ +synthesis quality 를 유지하면서도 inference speed ⬆️




Method

- perceptual compression : autoencoder
 - image space 와 인지적으로(perceptually) 동등한 space를 학습하면서도 computational complexity 가 크게 감소하는 autoencoding model 을 활용
 - 장점
 - high-dimensional image space 에서 벗어나 low-dimensional space 에서 sampling 이 수행되므로 훨씬 효율적인 DMs를 얻음.
 - UNet architecture based DM 의 inductive bias 을 활용하여 spatial structure 를 가진 data 에 특히 효과적이다.
→ 기존 연구에서 요구하는 높은 spatial compression 을 완화
- LDMs model



Perceptual Image Compression (Pixel Space \leftrightarrow Latent Space)

- perceptual compression model: AutoEncoder (ϵ, D)



- 인코더(encoder) $\epsilon: x \rightarrow z$ (latent representation)
- 디코더(decoder) $D: z$ (latent representation) $\rightarrow \tilde{x}$

고차원의 이미지(x)를 잘 표현하는 manifold 인 latent representation z 추출
 \rightarrow reconstruction 이미지(\tilde{x}) 로 복원

data

- $x \in \mathbb{R}^{H \times W \times 3}$: RGB 공간의 이미지
- encoder $\epsilon: x$ 를 latent representation $z = \epsilon(x)$ 으로 인코딩 $\Rightarrow x$ downsampling (factor $f = H/h = W/w$)
- $z \in \mathbb{R}^{h \times w \times c} = \epsilon(x)$: latent representation (2-dimensional structure)
- decoder D : latent representation(z) 를 single pass로 decoding 하여 $\tilde{x} = D(z) = D(\epsilon(x))$ 를 제공
- $\tilde{x} = D(z) = D(E(x))$: reconstruction 이미지

본 논문에서는 각기 다른 downsampling factor $f = 2^m$, $m \in \mathbb{N}$ 에 대해 실험

Latent Diffusion Models

- **Diffusion Model**

- generative model(GAN, VAE, Flow-based models, Diffusion models)
: 새로운 data instance를 생성해내는 모델 \Rightarrow Training Data distribution에 근사하는 특성

- 2가지 가정

1. 이산 마코프 가정(Discrete Markov Process Assumption)

$$P[s_{t+1} | s_t] = P[s_{t+1} | s_1, \dots, s_t]$$

- Markov 성질 : “특정 상태의 확률(t+1)은 오직 현재(t)의 상태에 의존한다.”
- 이산 확률과정 : 이산적인 시간(0초, 1초, 2초, ..) 속에서의 확률적 현상

1. 정규성(Normality) 가정 : “특정 데이터가 정규 분포를 따를것이다.”

\rightarrow 1+2 : 평균과 분산(μ, Σ)이라는 두가지 모수에 의해 결정되는 정규분포 그래프로서 Diffusion Model에서는 각 확률 단계가 Normal Distribution을 따를것이라 가정

$$p_{\theta}(X_{t-1} | X_t) = N(X_t; \mu_{X_{t-1}}, \Sigma_{X_{t-1}})$$

- 2가지 가정과 Diffusion Model

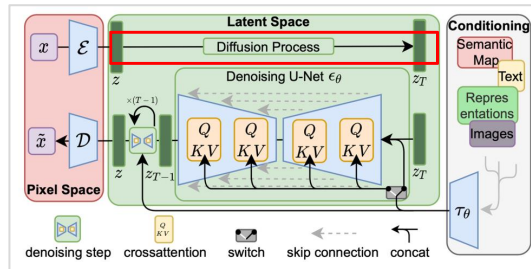
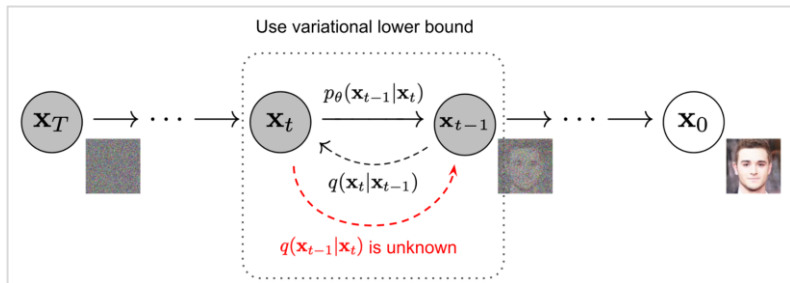
Markov 가정과 간단한 분포(정규분포)를 단계별로 활용하여 점차 복잡한 데이터를 표현하는 것이 Diffusion Model의 핵심

Latent Diffusion Models

• Diffusion Model

denoising process 를 통해 data distribution $p(x)$ 를 학습하는 probabilistic model

→ denoising process : length T 의 fixed Markov Chain의 reverse process 학습



• Forward diffusion process q

: 샘플 이미지 x_0 가 시점 0-T 까지 작은 gaussian noise를 줘서 최종적으로 노이즈로 이루어진 x_T 를 만드는 과정

- noise: 정규성 가정에 따라 정규 분포 형태를 따르는 임의의 Gaussian Noise 주입
- $x_1 : x_0$ 에 noise 적용한 이미지 → $q(x_1|x_0)$
time t 에 대해 general 하게 표현한다면 $q(x_t|x_{t-1})$ 으로 표현할 수 있다.

LDMs: latent representation $z = \epsilon(x)$ (latent space에 매핑) → z_T (noised latent representation)

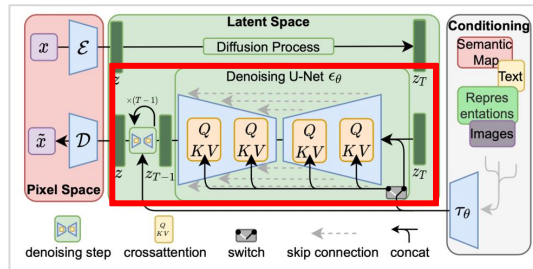

→ $t-1$ 에서 t 번째 이미지가 되는 과정은 정의한 노이즈에 따라서 바로 알아낼 수 있어 학습이 필요 없지만 반대 과정은 알 수 없기 때문에 학습이 필요

Latent Diffusion Models

- Diffusion Model**

denoising process 를 통해 data distribution $p(x)$ 를 학습하는 probabilistic model

→ denoising process : length T 의 fixed Markov Chain의 reverse process 학습



- Reverse process**

: $q(x_t|x_{t-1})$ 와는 반대로 점진적으로 noise 를 걷어내는 denoising process $q(x_{t-1}|x_t)$

BUT, 노이즈가 추가된 데이터를 완벽하게 원래 상태로 되돌리는것은 불가능한 일

$$p_{\theta}(x_{t-1} | x_t) \approx q(x_{t-1} | x_t)$$

*학습 대상

→ $q(x_{t-1}|x_t)$ 가 아닌 model의 가정을 만족하면서도 $q(x_{t-1}|x_t)$ 와 최대한 유사한 분포 $p_{\theta}(x_{t-1}|x_t)$ 를 찾는다.

LDMs : noised latent representation z_T 에서 latent representation z 로 denoising

Latent Diffusion Models

- Diffusion Model objective

$$L_{DM} = \mathbb{E}_{x, \epsilon \sim \mathcal{N}(0,1), t} \left[\|\epsilon - \epsilon_{\theta}(x_t, t)\|_2^2 \right], \quad (1)$$

이 모델은 denoising autoencoder $\epsilon_{\theta}(x_t, t)$; $t=1, \dots, T$ 의 weighted sequence로 볼 수 있으며, noisy input x_t 로 부터 원본 이미지 x 를 predict


- ϵ : noise, forward diffusion process 를 진행할 때 사용한 실제 noise 값
- ϵ_{θ} : denoising autoencoder
- x_t : noised sample
- t : noise level, $[t-1, t-2, \dots, 0]$ (less-noisy)
- $\epsilon_{\theta}(x_t, t)$: denoising process 의 noise

L_{DM} : $t \rightarrow t-1$, [실제 noise - denoising process 의 noise] 값을 줄여나가는 과정 (loss minimize)

→ 실제 분포와 근사한 분포를 만들어내기 위해 noising process 사용했던 noise ϵ 에 근사시키는 네트워크를 학습하는 것

Latent Diffusion Models

- Generative Modeling of Latent Representations



- Latent Diffusion Model objective


$$L_{LDM} := \mathbb{E}_{\mathcal{E}(x), \epsilon \sim \mathcal{N}(0,1), t} \left[\|\epsilon - \epsilon_\theta(z_t, t)\|_2^2 \right]. \quad (2)$$

- denoising model neural backbone $\epsilon_\theta(\cdot, t)$: time-conditional UNet
- x_t : noised sample $\rightarrow z_T$: noised latent representation($\mathcal{E}(x)$)

L_{LDM} : Diffusion Process($z \rightarrow z_T$)사용했던 noise ϵ 에 근사시키는 네트워크를 학습하는 것

Conditioning Mechanisms

- semantic compression





- LDM은 다양한 modalities 적용하기 위해 **conditioning input y** 도입
- diffusion model은 conditional distribution을 $p(z|y)$ 로 모델링 가능 \rightarrow conditional denoising autoencoder $\epsilon_\theta(z_T, t, y)$ 로 구현
 - 이미지 생성을 위한 conditioning input y (text, semantic maps)를 컨트롤하거나, image-to-image translation task를 수행

BUT, conditioning input y 를 denoising autoencoder ϵ_θ 에 적용하기 위해서는 preprocessing 필요!

- preprocessing[text/image transformer]: **domain specific encoder τ_θ** 도입
 - conditioning input y 를 다양한 modalities(language prompts, semantic 맵과 같은)로부터 전처리하기 위해 τ_θ 도입
 - domain specific encoder τ_θ : conditioning input $y \rightarrow$ intermediate representation $\tau_\theta(y) \in \mathbb{R}^{M \times d_T}$ 로 project 한다.
 - semantic compression**: ϵ_θ 의 intermediate layers에 적합하게 encoding

Conditioning Mechanisms

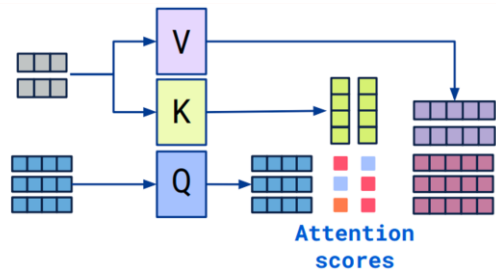

- conditional denoising autoencoder $\epsilon_\theta(z_T, t, y)$



- denoising model neural backbone $\epsilon_\theta(\cdot, t)$: **time-conditional UNet structure**
 - autoencoder 와 같은 encoder-decoder 기반 모델
 - Contracting Path(encoder) : 이미지의 context 포착
 - Expansive Path(decoder) : encoder의 최종 feature map을 upsampling & context와 결합 \rightarrow localization 수행
 - skip connection: 인코더 레이어와 디코더 레이어의 직접 연결
 - concatenation: 이미지의 위치와 특징을 추출하기 위해 인코딩 단계의 각 레이어에서 얻은 특징을 디코딩 단계의 각 레이어에 합친다.
- ϵ_θ **intermediate layers**: cross-attention mechanism 적용
 - UNet backbone을 다양한 input modality에 대해 conditioning 할 수 있도록 cross-attention mechanism 으로 구성 \rightarrow cross-attention mechanism 을 통해 다양한 input modality 를 model 에 적용

Conditioning Mechanisms

- conditional denoising autoencoder $\epsilon\theta(z_T, t, y)$



- UNet 의 intermediate layers** : cross-attention layer 로 구성
 - Attention(Q, K, V) = softmax(QK^T/√d_k) · V가 구현
 - cross attention: 2 개의 embedding sequences 간의 correlation 학습
 - input: Query, Key, Value
 - key, value 의 경우 같은 sequence 에서 얻지만, query는 다른 sequence에서 얻음.(즉, query 출처 ≠ key, value 출처)

$$Q = W_Q^{(i)} \cdot \varphi_i(z_t), K = W_K^{(i)} \cdot \tau_\theta(y), V = W_V^{(i)} \cdot \tau_\theta(y).$$

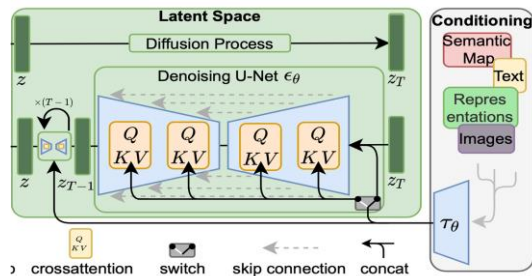
- $Q : \varphi_i(z_t) \in \mathbb{R}^{N \times d_{i-1}^e}$: encoder ϵ_θ 을 구현하는 UNet 의 (flattened) intermediate representation
- $W_V^{(i)} \in \mathbb{R}^{d \times d_{i-1}^e}$, $W_Q^{(i)}$ & $W_K^{(i)} \in \mathbb{R}^{d \times d_r}$: learnable projection matrices
- LDM cross-attention**: Q (intermediate representation) 을 생성할 때, conditioning input y 의 어떤 정보를 Attention 해야할지 파악하는 과정
 - conditioning input y를 참고해서 noised latent representation z_T 를 denoising

Conditioning Mechanisms

- conditional Latent Diffusion Model objective

$$L_{LDM} := \mathbb{E}_{\mathcal{E}(x), y, \epsilon \sim \mathcal{N}(0,1), t} \left[\|\epsilon - \epsilon_{\theta}(z_t, t, \tau_{\theta}(y))\|_2^2 \right], \quad (3)$$


- $\tau_{\theta}, \epsilon_{\theta}$: Eq. 3 을 통해 optimized
- this conditioning mechanism is flexible




- autoencoder loss (perceptual loss + a patch-based adversarial objective)

- perceptual loss: feature map 거리 계산


- input 이미지 $x \rightarrow$ image transform net \rightarrow output y^{\wedge}
- y_c : content target, y_s : style target



- patch based adversarial objective: patch 단위로 T/F를 판별하는 방식
: local realism 실현, (L2 or L1 objectives)처럼 pixel 단위 loss를 사용했을 때 발생하는 blurriness 현상을 완화하여 reconstruction 이 image manifold 에만 국한되도록 보장



LDM process



1. perceptual compression ϵ

: $x \rightarrow$ latent representation $z = \epsilon(x)$ (latent space에 매핑)

2. diffusion process

: latent representation $z \rightarrow z_T$ (noised latent representation)

3. conditioning mechanism & semantic compression τ_θ

: conditioning input $y \rightarrow$ intermediate representation $\tau_\theta(y)$

4. denoising process

: $\tau_\theta(y)$ 를 참고하여 noised latent representation $z_T \rightarrow$ latent representation z

5. perceptual compression \mathcal{D}


: latent representation $z \rightarrow$ reconstruction 이미지 $\tilde{x} = \mathcal{D}(z)$

Experiments

- **On Perceptual Compression Tradeoffs:** different downsampling factors f 를 가진 LDMs 평가

- downsampling factors f
 - $f \in \{1, 2, 4, 8, 16, 32\}$; LDM- f 로 부름.
 - LDM-1 : pixel-based DMs
- computational resources
 - a single NVIDIA A100 으로 고정
 - 동일한 steps 과 parameters 개수로 train

□ class-conditional LDMs 의 sample quality



ImageNet dataset 으로 training progress(2M train steps) 를 걸쳐 downsampling factors f 를 적용

- LDM-{4-16} : efficiency and perceptual 간의 좋은 균형을 보임
- small downsampling factors for LDM-{1,2} : slow training progress
- 지나치게 높은 f (LDM-32) : 적은 training steps 후, sample quality 를 제한
 - 강한 perceptual compression 이 information loss 를 일으키고 sample quality 를 제한하기 때문

Experiments

- **Conditional Latent Diffusion - Transformer Encoders for LDMs**

- text-to-image image modeling,
 - LAION-400M 에서 language prompts 에 따라 condition 된 parameter model 을 train
 - BERT-tokenizer 를 사용하고 τ_θ 을 transformer 로 구현하여 cross-attention 을 통해 UNet latent code 를 생성한다.
 - [language representation \leftrightarrow visual synthesis] 를 학습하기 위한 domain specific encoder τ_θ 는 user-defined text prompts 로 일 반화

□ <Text-To-Image>



Samples from our text-to-image LDM model for user-defined text prompts, which is trained on LAION-400M.

Experiments

- **Conditional Latent Diffusion - Convolutional Sampling Beyond 256^2**

- image-to-image translation models
 - spatially 하게 정렬된 conditioning information 을 ϵ_θ input에 concat 함으로써 LDMs 은 image-to-image translation models 구현
 - large resolution
 - input resolution 256^2 (crops from 384^2) 에 대해 train 하지만, 해당 모델은 larger resolutions 으로 일반화되며 convolutional 방식을 사용할 때 megapixel 까지 이미지를 생성할 수 있다.
 - super-resolution models과 inpainting models에 적용하여 512^2 and 1024^2 사이의 이미지 생성
- large resolution ($256 \times 256 \rightarrow 512 \times 1024$)



256^2 resolution 으로 train된 LDM을 풍경 이미지의 conditioned tasks 에 대해 larger resolution (here: 512×1024) 으로 일반화

Experiments

- **Super-Resolution with Latent Diffusion**

- concatenation을 통해 low-resolution image을 직접 conditioning함으로써 super-resolution을 train
 - 실험 방법
 - SR3 based, image degradation을 4×-downsampling 후, bicubic interpolation 으로 수정하고 SR3's data processing pipeline 을 따라 ImageNet 으로 train
 - f = 4 autoencoding model pretrained on OpenImages 사용하고 low-resolution conditioning y 를 UNet 의 inputs 으로 연결
- ❑ ImageNet 64→256 super-resolution on ImageNet-Val.



- LDM-SR: realistic textures rendering
- SR3: 일관된 fine structures 를 합성할 수 있다.

Experiments

• Inpainting with Latent Diffusion

- inpainting
 - masked regions of an image 을 새로운 콘텐츠로 채우거나 대체하는 작업

□ Comparison of inpainting performance

Method	40-50% masked		All samples	
	FID ↓	LPIPS ↓	FID ↓	LPIPS ↓
<i>LDM-4</i> (ours, big, w/ ft)	9.39	0.246 ± 0.042	1.50	0.137 ± 0.080
<i>LDM-4</i> (ours, big, w/o ft)	12.89	0.257 ± 0.047	2.40	0.142 ± 0.085
<i>LDM-4</i> (ours, w/ attn)	11.87	0.257 ± 0.042	2.15	0.144 ± 0.084
<i>LDM-4</i> (ours, w/o attn)	12.60	0.259 ± 0.041	2.37	0.145 ± 0.084
LaMa [85] [†]	12.31	0.243 ± 0.038	2.23	0.134 ± 0.080
LaMa [85]	12.0	0.24	2.21	<u>0.14</u>
CoModGAN [103]	<u>10.4</u>	0.26	<u>1.82</u>	0.15
RegionWise [51]	21.3	0.27	4.75	0.15
DeepFill v2 [100]	22.1	0.28	5.20	0.16
EdgeConnect [57]	30.5	0.28	8.37	0.16

□ 사용자 preference 연구

User Study	SR on ImageNet		Inpainting on Places	
	Pixel-DM (<i>f1</i>)	<i>LDM-4</i>	LAMA [85]	<i>LDM-4</i>
Task 1: Preference vs GT ↑	16.0%	30.4%	13.6%	21.0%
Task 2: Preference Score ↑	29.4%	70.6%	31.9%	68.1%

- Task 1: ground truth, generated image 중 preference 요청
- Task 2: 2개의 generated images 중 preference 요청



Conclusion

- quality 를 저하시키지 않으면서도 denoising diffusion model 의 training and sampling efficiency 크게 향상시킬 수 있는 latent diffusion model 제시
- cross-attention conditioning mechanism 을 기반으로, Task 별 별도의 아키텍처가 없는 광범위한 Conditional Image Synthesis task 에 다른 SOTA 모델들과 비교해도 손색이 없었다.